Reporte de segmentación con GrabCut

Franco Castro Chaves
C01886

Emily Chacón Araya
C02047

10 de octubre de 2026

Resumen

Se estudia una implementación de segmentación interactiva basada en GrabCut para delimitar schwannoma vestibular en cortes de resonancia magnética. El conjunto de trabajo comprende 30 imágenes PNG asociadas a la colección Vestibular-Schwannoma-SEG. El procedimiento inicializa las etiquetas mediante un rectángulo, modela las intensidades de fondo y primer plano con cinco gaussianas por clase y alterna la actualización de estos modelos con cortes mínimos en un grafo de ocho vecinos. La evaluación presentada corresponde al caso `VS-SEG-001` y utiliza una máscara binaria extraída de su anotación roja. Tras cinco iteraciones, se obtuvieron 47 falsos positivos y 84 falsos negativos, con un error cuadrático medio de 0,000500 sobre la imagen completa y de 0,026422 dentro del rectángulo. Las discrepancias se redujeron un 92,25 % respecto de una predicción de todo fondo. Las etiquetas permanecieron sin cambios desde la tercera iteración hasta la quinta, aunque los modelos de intensidad continuaron actualizándose. El análisis ilustra el comportamiento del procedimiento en el corte seleccionado.

Índice

1. Introducción **2**

2. Datos **2**
2.1. Procedencia y adquisición 2
2.2. Selección y preparación de las imágenes 3
2.3. Referencia de segmentación 3

3. Metodología **3**
3.1. Imagen de entrada e inicialización 3
3.2. Modelos de intensidad 4
3.3. Energía y coherencia espacial 5
3.4. Construcción del grafo y corte mínimo 5
3.5. Iteración y registro 6
3.6. Evaluación por corte 6
3.7. Disponibilidad del código y aplicación web 7

4. Resultados **7**
4.1. Caso evaluado y primer corte 7
4.2. Evolución de la segmentación 7
4.3. Comparación con la referencia 8

5. Conclusiones **9**

Referencias **10**

1. Introducción

La segmentación de imágenes asigna etiquetas a los píxeles para delimitar regiones de interés [1]. En una imagen de resonancia magnética, la delimitación de una lesión requiere distinguirla de los tejidos circundantes a partir de su apariencia y de su organización espacial. Cuando distintas regiones presentan intensidades semejantes, una clasificación basada únicamente en la intensidad puede producir ambigüedades. Incorporar relaciones entre píxeles vecinos permite favorecer regiones coherentes, mientras que una selección interactiva restringe la búsqueda a la zona de interés [2].

GrabCut combina modelos de apariencia de fondo y primer plano con una penalización espacial dependiente del contraste. El procedimiento alterna la estimación de estos modelos con la actualización de etiquetas mediante cortes de grafos. Una inicialización rectangular permite indicar la región que contiene el objeto sin trazar de antemano su borde completo [3]. La segmentación obtenida depende tanto de la información de la imagen como de la restricción introducida por ese rectángulo.

En este trabajo se estudia una implementación de segmentación interactiva basada en GrabCut aplicada a cortes de resonancia magnética de schwannoma vestibular. Se utiliza un conjunto de trabajo de 30 imágenes PNG asociado a la colección *Vestibular-Schwannoma-SEG* [4], cuya procedencia y preparación se describen en la sección 2. Las imágenes se procesan individualmente en escala de grises. Para cada corte, la región candidata se delimita mediante un rectángulo y se construyen modelos de mezclas gaussianas para ambas clases. La coherencia espacial se incorpora mediante una vecindad de ocho píxeles y las etiquetas se actualizan por corte mínimo. La anotación roja disponible se transforma en una máscara binaria destinada a la evaluación.

El objetivo es describir la relación entre la inicialización interactiva, los modelos de intensidad y la optimización espacial, y examinar la segmentación resultante mediante comparaciones con la referencia. Se registra la evolución de las etiquetas y de la energía durante cinco iteraciones. La evaluación considera el error cuadrático medio sobre la imagen completa y sobre el rectángulo, los falsos positivos y negativos y su distribución espacial. Se incluye una predicción de todo fondo para interpretar el efecto del predominio de esta clase en el error global.

El procedimiento se ilustra con el caso `VS-SEG-001`, para el que se presentan la evolución de la segmentación y la comparación con su anotación de referencia.

2. Datos

2.1. Procedencia y adquisición

Se utilizan imágenes de resonancia magnética de la colección *Vestibular-Schwannoma-SEG*, publicada por Shapey y colaboradores en The Cancer Imaging Archive [5]. La colección comprende 242 pacientes adultos con schwannoma vestibular unilateral esporádico tratados mediante radiocirugía estereotáctica con Gamma Knife. Cada caso incluye imágenes ponderadas en T1 con contraste y en T2 de alta resolución, junto con estructuras segmentadas y datos de planificación de radioterapia. Los datos se distribuyen bajo la licencia de atribución CC BY 4.0 [4].

Las imágenes originales se adquirieron con un resonador Siemens Avanto de 1,5 T. La adquisición T1 con contraste empleó una secuencia MPRAGE, con una matriz de 512×512 píxeles y una resolución en el plano de $0{,}4 \times 0{,}4$ mm. La adquisición T2 de alta resolución empleó una secuencia 3D CISS, con matrices de 384×384 o 448×448 píxeles y una resolución en el plano de aproximadamente $0{,}5 \times 0{,}5$ mm. El espesor de corte fue de 1,0 a 1,5 mm. Las estructuras de referencia fueron delimitadas por el equipo clínico mediante Leksell GammaPlan, empleando las imágenes T1 con contraste y T2 de alta resolución. Estos parámetros describen la adquisición clínica de la colección [6].

2.2. Selección y preparación de las imágenes

El conjunto de trabajo comprende 30 imágenes bidimensionales, una por cada caso identificado desde `VS-SEG-001` hasta `VS-SEG-030`. Según la selección documentada en la presentación del proyecto [7], 13 cortes corresponden a T1 con contraste y 17 a T2 de alta resolución. La tabla 1 resume esta composición y las dimensiones verificadas en los archivos. La distribución de tamaños concuerda con las matrices de adquisición publicadas [6].

Tabla 1: Composición del conjunto de trabajo. La secuencia corresponde a la clasificación documentada en la presentación; las dimensiones y cantidades se verificaron en los archivos del repositorio [8].

Secuencia	Dimensiones (píxeles)	Cantidad
T1 con contraste	512×512	13
T2 de alta resolución	448×448	16
T2 de alta resolución	384×384	1
Total		30

Las imágenes se extrajeron y convirtieron a PNG, tanto en su versión sin superposición como en su versión con la anotación roja. El repositorio conserva las primeras en `data/images/`, en escala de grises de 8 bits, y las segundas en `data/contours/`, con canales rojo, verde y azul. Ambos archivos comparten el identificador del caso. El análisis utiliza estos cortes bidimensionales como unidades de procesamiento.

2.3. Referencia de segmentación

La implementación extrae una máscara binaria de la anotación roja [8]. Para el píxel i, sean r_i, v_i y b_i las intensidades de los canales rojo, verde y azul, respectivamente. La etiqueta de referencia se define como

$$g_i = \begin{cases} 1, & r_i > v_i \text{ y } r_i > b_i, \\ 0, & \text{en otro caso.} \end{cases} \tag{1}$$

La referencia contiene entre 70 y 2748 píxeles positivos por imagen. En los 30 casos se verificó que la imagen y su anotación tienen las mismas dimensiones y que todos los píxeles exteriores a la región roja coinciden exactamente. Esta comprobación respalda la correspondencia espacial entre los archivos locales. La máscara se utiliza para evaluar la segmentación; no se suministra como etiqueta de entrada a GrabCut.

La máscara obtenida mediante la ecuación (1) permite comparar la segmentación calculada con la región marcada en la anotación de cada imagen.

3. Metodología

3.1. Imagen de entrada e inicialización

Se emplea una implementación de segmentación interactiva basada en GrabCut para imágenes bidimensionales en escala de grises. El procedimiento alterna la estimación de modelos de intensidad para el fondo y el primer plano con la actualización de etiquetas mediante cortes de grafos. La descripción siguiente corresponde a la implementación del cuaderno del proyecto [8], basada en los principios de GrabCut [3]. OpenCV se utiliza para leer las imágenes y transformar sus canales; la segmentación se calcula mediante las funciones del cuaderno y no mediante una llamada a `cv2.grabCut`.

Sea Ω el conjunto de píxeles de la imagen y $x_i \in [0, 255]$ la intensidad del píxel i. La imagen PNG se carga en escala de grises y las intensidades se convierten a precisión doble para los

cálculos. No se aplica una normalización adicional, filtrado ni cambio de tamaño en el procedimiento del cuaderno. La unidad de procesamiento es un corte; cada ejecución selecciona un caso mediante su identificador.

La interacción consiste en delimitar sobre la imagen un rectángulo R que contenga la lesión y un margen de tejido circundante, conforme al esquema de inicialización rectangular de GrabCut [3]. Sus coordenadas se expresan en píxeles enteros. Se inicializan las etiquetas como

$$\alpha_i^{(0)} = [i \in R], \tag{2}$$

donde los corchetes valen uno cuando se cumple la condición y cero en caso contrario. Las etiquetas pertenecen a $\{0, 1\}$. La etiqueta cero representa fondo y la etiqueta uno, primer plano. Durante toda la optimización se impone $\alpha_i = 0$ para $i \notin R$. Las etiquetas interiores pueden cambiar. Por tanto, el rectángulo define el dominio de búsqueda y no la segmentación final. La inicialización requiere muestras suficientes dentro y fuera del rectángulo para formar los cinco grupos de cada modelo.

3.2. Modelos de intensidad

Para cada clase $a \in \{0, 1\}$ se modela la intensidad mediante una mezcla de $K = 5$ distribuciones gaussianas unidimensionales. Esta es una adaptación escalar del modelo de apariencia de GrabCut [3]:

$$p(x_i \mid a; \theta) = \sum_{k=1}^{K} w_{ak} \mathcal{N}(x_i; \mu_{ak}, \sigma_{ak}^2), \tag{3}$$

donde θ reúne los pesos w_{ak}, las medias μ_{ak} y las varianzas σ_{ak}^2. Los pesos de cada clase satisfacen

$$\sum_{k=1}^{K} w_{ak} = 1. \tag{4}$$

En la implementación del cuaderno [8], la inicialización ordena las intensidades de cada clase y las divide en cinco grupos de tamaño aproximadamente igual. El peso inicial de cada componente es la fracción de muestras de su grupo. Su media y varianza se calculan a partir de esas muestras, añadiendo $\varepsilon = 10^{-6}$ a la varianza.

En cada iteración, cada píxel se asigna al componente de mayor contribución ponderada dentro de su clase actual, siguiendo el esquema de asignación única de componentes [3]. De forma equivalente,

$$k_i = \arg\min_k d_{\alpha_i k}(x_i), \tag{5}$$

donde el costo de cada componente es

$$d_{ak}(x_i) = -\log w_{ak} + \tfrac{1}{2} \log(2\pi\sigma_{ak}^2) + \frac{(x_i - \mu_{ak})^2}{2\sigma_{ak}^2}. \tag{6}$$

El logaritmo es natural. Los componentes de peso cero tienen costo infinito. La asignación es única y no modifica todavía la clase del píxel.

Sean X_{ak} las muestras asignadas al componente k de la clase a, $N_{ak} = |X_{ak}|$ y $N_a = \sum_k N_{ak}$. Los parámetros se actualizan como

$$w_{ak} = \frac{N_{ak}}{N_a}, \tag{7}$$

$$\mu_{ak} = \frac{1}{N_{ak}} \sum_{x_i \in X_{ak}} x_i, \tag{8}$$

$$\sigma_{ak}^2 = \frac{1}{N_{ak}} \sum_{x_i \in X_{ak}} (x_i - \mu_{ak})^2 + \varepsilon. \tag{9}$$

Un componente sin muestras recibe peso cero y conserva su media y varianza anteriores. Si una clase queda vacía, se conservan todos sus parámetros. El costo de asignar el píxel a una clase se calcula con la mezcla completa [8]:

$$D_i(a;\theta) = -\log p(x_i \mid a;\theta). \tag{10}$$

La suma se evalúa en el dominio logarítmico para reducir problemas de precisión numérica. Esta elección difiere de la energía con componentes explícitos del artículo original [3]: la asignación de componentes se utiliza para ajustar los parámetros, pero el costo del corte marginaliza sobre todos los componentes.

3.3. Energía y coherencia espacial

La segmentación combina el costo de intensidad con una penalización por asignar etiquetas diferentes a píxeles vecinos, siguiendo la formulación de segmentación por grafos [2, 3]:

$$E(\alpha;\theta) = \sum_{i\in\Omega} D_i(\alpha_i;\theta) + \sum_{\{i,j\}\in\mathcal{N}} v_{ij}[\alpha_i \neq \alpha_j]. \tag{11}$$

El conjunto $\mathcal{N}$ contiene los pares de una vecindad de ocho vecinos, contando cada par una sola vez. Se emplean los pesos espaciales y la estimación de contraste descritos para imágenes escalares en [3]:

$$v_{ij} = \frac{\gamma}{d_{ij}} \exp[-\beta(x_i - x_j)^2], \tag{12}$$

donde

$$\beta = \left(\frac{2}{|\mathcal{N}|} \sum_{\{i,j\}\in\mathcal{N}} (x_i - x_j)^2 \right)^{-1}, \tag{13}$$

con $\gamma = 10$, valor fijado en el cuaderno [8]. Este valor es una elección de la implementación y no el ajuste $\gamma = 50$ reportado en el artículo original [3]. La distancia d_{ij} vale uno para vecinos horizontales y verticales, y $\sqrt{2}$ para diagonales, en unidades de píxel. El parámetro β se estima sobre toda la imagen; si todas las diferencias son nulas, se fija en cero. Los pesos elevados penalizan separar píxeles de intensidad similar, mientras que las diferencias grandes reducen la penalización. Estos pesos permanecen fijos durante las iteraciones.

3.4. Construcción del grafo y corte mínimo

La representación mediante terminales y enlaces entre vecinos sigue el principio de los cortes de grafos para segmentación [2]. En el cuaderno, el grafo incluye únicamente los píxeles de R como nodos variables [8]. El efecto de los vecinos exteriores, fijados como fondo, se incorpora al costo de primer plano mediante

$$q_i = \sum_{\substack{j\notin R \\ \{i,j\}\in\mathcal{N}}} v_{ij}, \tag{14}$$

$$\widetilde{D}_i(a;\theta) = D_i(a;\theta) + a q_i. \tag{15}$$

Así, la energía que depende de las etiquetas interiores es

$$E_R(\alpha;\theta) = \sum_{i\in R} \widetilde{D}_i(\alpha_i;\theta) + \sum_{\substack{\{i,j\}\in\mathcal{N} \\ i,j\in R}} v_{ij}[\alpha_i \neq \alpha_j]. \tag{16}$$

Para modelos fijos, la diferencia entre E y E_R es el costo constante $\sum_{i\notin R} D_i(0;\theta)$ y no cambia el corte óptimo.

Se añaden una fuente s, asociada al primer plano, y un sumidero t, asociado al fondo. Para obtener capacidades no negativas, se resta de ambos costos de cada píxel el valor $m_i = \min\{\widetilde{D}_i(0;\theta), \widetilde{D}_i(1;\theta)\}$. Las capacidades terminales son

$$c(s,i) = \widetilde{D}_i(0;\theta) - m_i, \tag{17}$$

$$c(i,t) = \widetilde{D}_i(1;\theta) - m_i. \tag{18}$$

Cada par de vecinos interiores se conecta mediante dos arcos opuestos de capacidad v_{ij}. Si las etiquetas difieren, el costo del corte incluye una sola contribución v_{ij}.

El flujo máximo se calcula mediante el algoritmo de Dinic [9], con tolerancia residual de 10^{-10} fijada en la implementación [8]. El procedimiento alterna la construcción de niveles en el grafo residual con el envío de flujo, hasta que el sumidero deja de ser alcanzable desde la fuente. Los píxeles interiores que permanecen alcanzables reciben la etiqueta uno; los demás reciben cero. Con los modelos fijos, la equivalencia entre flujo máximo y corte mínimo permite minimizar la energía binaria [2, 1] de la ecuación (16), salvo tolerancia numérica. Su valor se recupera sumando $\sum_{i\in R} m_i$ al flujo máximo.

3.5. Iteración y registro

La ejecución completa parte de las etiquetas de la ecuación (2) y de modelos recién inicializados. La ejecución configurada en el cuaderno realiza cinco iteraciones [8]. En cada una se asignan los componentes, se actualizan los parámetros gaussianos, se recalculan los costos y se obtiene un nuevo corte mínimo. El exterior del rectángulo y los pesos espaciales permanecen fijos. Se conserva la máscara de cada iteración y se registra el número de etiquetas modificadas. Las cinco iteraciones se ejecutan incluso si las etiquetas dejan de cambiar; no se utiliza una condición de parada basada en convergencia.

Para cada iteración ℓ, se comparan las energías anterior y posterior al corte con los mismos modelos actualizados $\theta^{(\ell)}$:

$$E_R(\alpha^{(\ell)};\theta^{(\ell)}) \le E_R(\alpha^{(\ell-1)};\theta^{(\ell)}). \tag{19}$$

Esta propiedad corresponde al paso de corte. La estimación de parámetros emplea asignaciones únicas de componentes, mientras que el costo de clasificación utiliza la mezcla completa. Por ello, el reajuste de las gaussianas no garantiza una disminución de esta energía entre iteraciones. La máscara de la quinta iteración constituye el resultado final.

3.6. Evaluación por corte

La segmentación final $\widehat{\alpha}$ se compara con la referencia g_i definida en la ecuación (1). Para un dominio de evaluación $A \subseteq \Omega$, la métrica implementada en el cuaderno [8] es el error cuadrático medio:

$$\mathrm{ECM}_A = \frac{1}{|A|}\sum_{i\in A}(\widehat{\alpha}_i - g_i)^2. \tag{20}$$

Se calcula para la imagen completa ($A = \Omega$) y para el rectángulo ($A = R$). Al tratarse de etiquetas binarias, cada discrepancia contribuye con uno; el error equivale a la proporción de píxeles mal clasificados. Además, se cuentan los falsos positivos y falsos negativos sobre toda la imagen y los píxeles de referencia que quedan fuera de R. Estos últimos no pueden recuperarse porque el exterior permanece fijado como fondo.

Se incluye como comparación una predicción que asigna fondo a todos los píxeles. Esta comparación permite interpretar un error global pequeño cuando la lesión ocupa una fracción reducida de la imagen. La inspección visual reúne la anotación, la máscara de referencia, la segmentación y un mapa de errores dentro del rectángulo. Las métricas globales incluyen los errores exteriores que no aparecen en esa visualización.

3.7. Disponibilidad del código y aplicación web

Todo el código del proyecto se encuentra en el repositorio *horus-grabcut* [10], disponible en `https://github.com/DarthFranco2001/horus-grabcut`. El cuaderno de procesamiento se ubica en `notebooks/`; el código de la aplicación web y sus pruebas, en `web/`; y las imágenes y anotaciones utilizadas, en `data/`. La referencia al cuaderno identifica la copia local de la que proceden las salidas de este reporte.

La aplicación *Laboratorio GrabCut* [11] está disponible en línea. Permite seleccionar un caso, delimitar el rectángulo de interés, ejecutar la segmentación y consultar la comparación con la referencia. El procesamiento se realiza en el navegador. La aplicación ofrece un medio interactivo para explorar el procedimiento; los resultados cuantitativos presentados en este reporte corresponden a la ejecución del cuaderno descrita en la sección 4.

4. Resultados

4.1. Caso evaluado y primer corte

Se presentan los resultados guardados en el cuaderno para el caso `VS-SEG-001` [8]. La imagen contiene 512×512 píxeles y el rectángulo seleccionado comprende 4958 píxeles. La referencia contiene 1690 píxeles positivos, todos dentro del rectángulo. El grafo reducido incluye 4958 nodos variables y 19 411 pares internos de vecinos; 278 píxeles interiores tienen conexiones con el fondo exterior. El parámetro de contraste calculado sobre la imagen fue $\beta = 0{,}001448$, con $\gamma = 10$.

El primer corte mínimo produjo una región de 1685 píxeles de primer plano. La figura 1 muestra la imagen y la segmentación dentro del rectángulo. La región segmentada sigue la zona de mayor intensidad asociada a la lesión. La proximidad entre su tamaño y el de la referencia no establece por sí sola una coincidencia espacial, por lo que la evaluación final considera las discrepancias píxel a píxel.

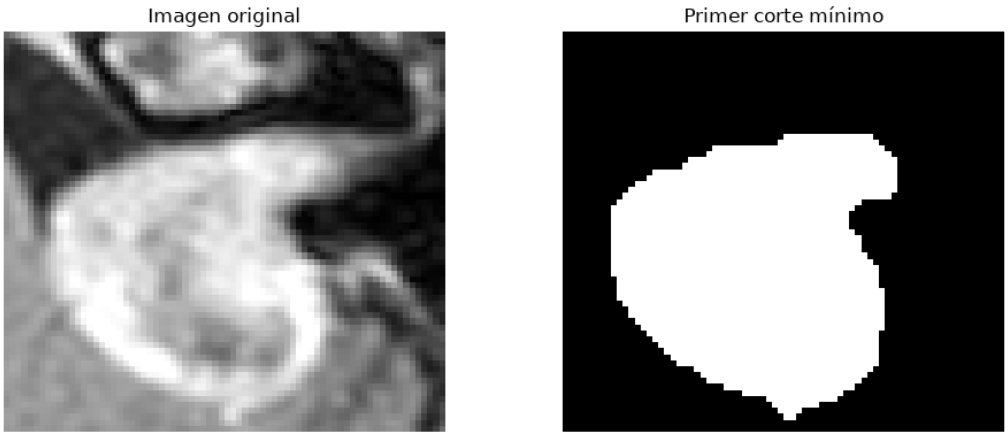


Figura 1: Imagen de entrada y primer corte mínimo para `VS-SEG-001`, recortados al rectángulo seleccionado. El blanco representa el primer plano y el negro, el fondo en la segmentación. La región obtenida contiene 1685 píxeles. Figura exportada de la salida conservada en el cuaderno [8]; imagen de origen [4].

4.2. Evolución de la segmentación

La primera iteración cambió 3273 etiquetas respecto de la inicialización, en la que todos los píxeles interiores pertenecían al primer plano. La segunda modificó 54 etiquetas y produjo una región de 1653 píxeles. Desde la tercera hasta la quinta iteración no se registraron cambios en las etiquetas. La tabla 2 presenta las energías reducidas antes y después de cada corte, calculadas con los modelos de esa iteración.

Tabla 2: Evolución de las cinco iteraciones para `VS-SEG-001`. Las energías corresponden a la ecuación (16). Cada comparación anterior–posterior utiliza los mismos parámetros gaussianos. Los valores se muestran con tres decimales.

Iteración	Etiquetas modificadas	Energía anterior	Energía posterior
1	3273	33040,453	29246,318
2	54	28085,150	28039,382
3	0	28021,789	28021,789
4	0	28013,209	28013,209
5	0	27996,347	27996,347

La energía disminuyó durante los dos primeros cortes y permaneció igual antes y después de los tres siguientes, a la precisión registrada. Aunque las etiquetas no cambiaron en esas últimas iteraciones, la energía varió entre ellas debido a la actualización de los modelos de intensidad. La estabilidad observada corresponde a las etiquetas durante las cinco iteraciones ejecutadas; no constituye una prueba de convergencia conjunta de todos los parámetros.

4.3. Comparación con la referencia

La segmentación final presentó 47 falsos positivos y 84 falsos negativos, para un total de 131 discrepancias. A partir de estos conteos y de los 1690 píxeles de referencia, se obtienen 1606 verdaderos positivos y 1653 píxeles clasificados como primer plano. La tabla 3 compara el resultado con la predicción que asigna fondo a toda la imagen.

Tabla 3: Evaluación del caso `VS-SEG-001`. Los falsos positivos (FP) y falsos negativos (FN) se cuentan sobre la imagen completa. El error cuadrático medio (ECM) se calcula sobre 262 144 píxeles para la imagen y sobre 4958 píxeles para el rectángulo.

Método	FP	FN	ECM global	ECM en el rectángulo
GrabCut	47	84	0,000500	0,026422
Todo fondo	0	1690	0,006447	0,340863

El error de GrabCut equivale aproximadamente al 0,050 % de la imagen y al 2,642 % del rectángulo. Frente a la predicción de todo fondo, el número de discrepancias se redujo aproximadamente un 92,25 %. Esta reducción se calcula con los conteos enteros, antes del redondeo de las métricas. La referencia ocupa solo el 0,645 % de la imagen, lo que explica que la predicción de todo fondo también presente un error global pequeño pese a omitir completamente la lesión.

La figura 2 muestra la anotación, la referencia, la segmentación final y la distribución espacial de las discrepancias. Los falsos positivos se observan principalmente en los extremos derecho e inferior de la región, mientras que los falsos negativos aparecen en porciones de su borde izquierdo e inferior. Predominan los píxeles de lesión correctamente identificados en el interior. Las diferencias se concentran en el límite de la región y no quedan descritas únicamente por su área total.

En el caso evaluado, la segmentación conservó la mayor parte de la región anotada y las discrepancias se concentraron en sus bordes. Las etiquetas se estabilizaron durante la ejecución, mientras continuaba el ajuste de los modelos de intensidad.

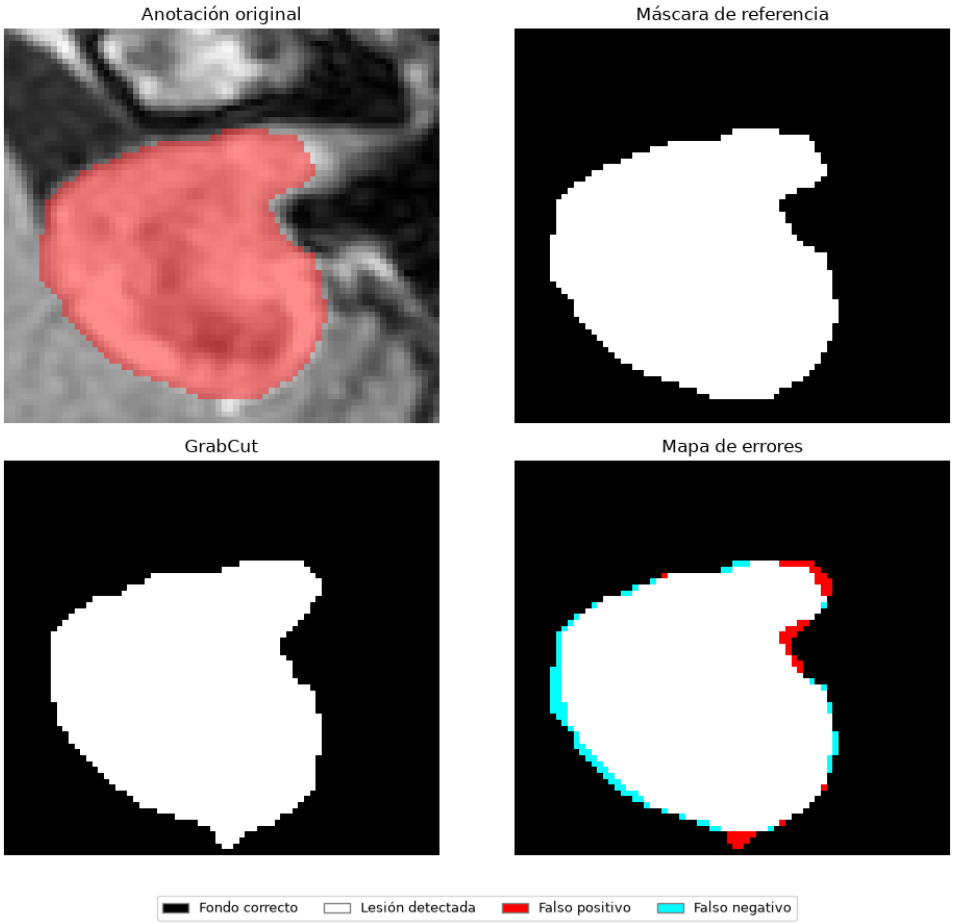


Figura 2: Comparación final para `VS-SEG-001` dentro del rectángulo. Arriba: anotación roja y máscara binaria de referencia. Abajo: segmentación tras cinco iteraciones y mapa de errores. En este último, el blanco indica lesión correctamente identificada; el negro, fondo correcto; el rojo, falsos positivos; y el cian, falsos negativos. No hay píxeles de referencia fuera del rectángulo. Figura exportada de la salida conservada en el cuaderno [8]; imagen de origen [4].

5. Conclusiones

La implementación de segmentación interactiva basada en GrabCut permitió obtener una región compatible con la referencia disponible para el corte `VS-SEG-001`, a partir de una inicialización rectangular. Tras cinco iteraciones, se registraron 47 falsos positivos y 84 falsos negativos. El error cuadrático medio fue de 0,000500 sobre la imagen completa y de 0,026422 dentro del rectángulo. Frente a la predicción que asigna fondo a todos los píxeles, las discrepancias se redujeron aproximadamente un 92,25 % en este caso.

Las etiquetas permanecieron sin cambios desde la tercera iteración hasta la quinta, aunque los modelos de intensidad continuaron actualizándose. El procedimiento combina así el ajuste de los modelos de intensidad con la minimización de la energía mediante cortes de grafos.

El predominio del fondo hace que el error global sea pequeño incluso cuando se omite toda la lesión. Por ello, su interpretación requiere considerar también el error dentro del rectángulo, los falsos positivos y negativos y su distribución espacial. En el caso evaluado, las discrepancias se concentraron en el límite de la región segmentada.

El caso estudiado ilustra la aplicación de GrabCut a la segmentación interactiva de una lesión en resonancia magnética. La inicialización rectangular delimita la región de búsqueda, los modelos gaussianos describen las intensidades de ambas clases y los enlaces entre vecinos favorecen la coherencia espacial de la región obtenida.

Referencias

[1] R. Szeliski (2011). *Computer Vision: Algorithms and Applications*. Primera edición, Springer. doi:10.1007/978-1-84882-935-0.

[2] Y. Y. Boykov y M.-P. Jolly (2001). Interactive Graph Cuts for Optimal Boundary & Region Segmentation of Objects in N-D Images. En *Proceedings of the Eighth IEEE International Conference on Computer Vision*, vol. 1, pp. 105–112. doi:10.1109/ICCV.2001.937505.

[3] C. Rother, V. Kolmogorov y A. Blake (2004). "GrabCut": Interactive Foreground Extraction Using Iterated Graph Cuts. *ACM Transactions on Graphics*, 23(3), 309–314. doi:10.1145/1015706.1015720.

[4] J. Shapey, A. Kujawa, R. Dorent, G. Wang, S. Bisdas, A. Dimitriadis, D. Grishchuck, I. Paddick, N. Kitchen, R. Bradford, S. Saeed, S. Ourselin y T. Vercauteren (2021). Segmentation of Vestibular Schwannoma from Magnetic Resonance Imaging: An Open Annotated Dataset and Baseline Algorithm. Versión 2, conjunto de datos *Vestibular-Schwannoma-SEG*, The Cancer Imaging Archive, licencia CC BY 4.0. doi:10.7937/TCIA.9YTJ-5Q73.

[5] K. Clark, B. Vendt, K. Smith, J. Freymann, J. Kirby, P. Koppel, S. Moore, S. Phillips, D. Maffitt, M. Pringle, L. Tarbox y F. Prior (2013). The Cancer Imaging Archive (TCIA): Maintaining and Operating a Public Information Repository. *Journal of Digital Imaging*, 26(6), 1045–1057. doi:10.1007/s10278-013-9622-7.

[6] J. Shapey, A. Kujawa, R. Dorent, G. Wang, A. Dimitriadis, D. Grishchuk, I. Paddick, N. Kitchen, R. Bradford, S. R. Saeed, S. Bisdas, S. Ourselin y T. Vercauteren (2021). Segmentation of vestibular schwannoma from MRI, an open annotated dataset and baseline algorithm. *Scientific Data*, 8, artículo 286. doi:10.1038/s41597-021-01064-w.

[7] F. Castro Chaves y E. Chacón Araya (2026). *Segmentación interactiva de tejidos con GrabCut: schwannoma vestibular en resonancia magnética*. Presentación del Foro Tema 4, PF-5039 Análisis de Imágenes, IIS-2026, diapositivas 10–12 y 16. Material del proyecto no publicado.

[8] Proyecto *horus-grabcut* (2026). Cuaderno de segmentación interactiva `notebooks/grabcut.ipynb` y archivos de `data/`. Copia local consultada el 10 de octubre de 2026; se utilizan sus salidas guardadas para `VS-SEG-001`. La copia local del cuaderno contiene modificaciones respecto de la versión registrada en Git. Repositorio del proyecto.

[9] E. A. Dinic (1970). Algorithm for Solution of a Problem of Maximum Flow in Networks with Power Estimation. *Soviet Mathematics Doklady*, 11, 1277–1280. Texto de la publicación en el sitio del autor.

[10] Proyecto *horus-grabcut* (2026). *horus-grabcut*. Repositorio de código fuente: cuaderno, aplicación web, datos de trabajo y pruebas. `https://github.com/DarthFranco2001/horus-grabcut`.

[11] Proyecto *horus-grabcut* (2026). *Laboratorio GrabCut*. Aplicación web interactiva. Consultada el 10 de octubre de 2026. `https://darthfranco2001.github.io/horus-grabcut/`.